

Laporan Praktikum IEEE: Analisis Komparatif Performa CNN from Scratch dan Transfer Learning (MobileNetV2) pada Klasifikasi Citra

ACHMAD FATICH AL FAHMI

Program Studi Teknik Informatika

Universitas Darussalam Gontor

NIM: 422021611002

achmadal-fahmi42002@mhs.unida.gontor.ac.id

Abstract—Penelitian praktikum ini bertujuan untuk mengevaluasi dan membandingkan efektivitas arsitektur Convolutional Neural Network (CNN) yang dirancang dari awal (from scratch) dengan metode Transfer Learning berbasis arsitektur pretrained MobileNetV2. Eksperimen 1 menerapkan CNN kustom pada dataset objek multi-kelas CIFAR-10 (32×32 piksel), sementara Eksperimen 2 menerapkan Transfer Learning Feature Extraction pada dataset biner Cats vs Dogs (160×160 piksel). Berdasarkan hasil pengujian pada GPU Tesla P100, CNN from scratch menghasilkan akurasi data testing sebesar 77.09% dengan total 362.282 parameter. Di sisi lain, Transfer Learning berbasis MobileNetV2 berhasil mencatatkan akurasi testing sebesar 98.11%. Hasil eksperimen mengonfirmasi bahwa Transfer Learning mencapai konvergensi yang jauh lebih cepat serta keandalan klasifikasi yang lebih tinggi berkat pemanfaatan fitur visual dari ImageNet.

Index Terms—Convolutional Neural Network, Transfer Learning, MobileNetV2, CIFAR-10, Cats vs Dogs, Image Classification.

I. PENDAHULUAN

Klasifikasi citra digital merupakan salah satu tugas mendasar dalam bidang *Computer Vision*. Pendekatan *Deep Learning*, khususnya *Convolutional Neural Network* (CNN), telah terbukti memberikan performa luar biasa dalam mengekstraksi fitur visual secara otomatis tanpa memerlukan rekayasa fitur manual (*feature engineering*). Namun, merancang arsitektur CNN dari awal (*from scratch*) sering kali membutuhkan sumber daya komputasi yang besar, durasi *training* yang lama, serta sampel data berlabel dalam jumlah masif untuk menghindari *overfitting*.

Sebagai alternatif, paradigma *Transfer Learning* memungkinkan pemanfaatan pengetahuan (bobot parameter) yang telah dipelajari oleh model *pretrained* pada dataset berskala besar seperti ImageNet. Laporan ini membahas analisis komparatif mendalam antara implementasi CNN kustom sederhana pada dataset CIFAR-10 dan implementasi *Transfer Learning* berbasis MobileNetV2 pada dataset Cats vs Dogs.

II. DESKRIPSI DATASET

Penelitian ini menggunakan dua jenis dataset publik yang diakses secara langsung melalui pustaka

`tf.keras.datasets` dan `tensorflow_datasets` (`tfd`s):

1) Dataset CIFAR-10 (Eksperimen 1):

- **Sumber:** University of Toronto (<https://www.cs.toronto.edu/~kriz/cifar.html>).
- **Karakteristik:** Terdiri dari 60.000 citra berwarna RGB berukuran 32×32 piksel yang terbagi ke dalam 10 kelas objek (airplane, automobile, bird, cat, deer, dog, frog, horse, ship, truck).
- **Pembagian Data:** 42.500 sampel *training* (85%), 7.500 sampel *validation* (15%), dan 10.000 sampel *testing*.

2) Dataset Cats vs Dogs (Eksperimen 2):

- **Sumber:** Repositori Resmi TensorFlow Datasets (https://www.tensorflow.org/datasets/catalog/cats_vs_dogs).
- **Karakteristik:** Dataset klasifikasi biner citra resolusi variabel yang dikonversi menjadi $160 \times 160 \times 3$ piksel. Berdasarkan log pengunduhan `cats_vs_dogs/4.0.1`, terdapat 1.738 gambar rusak (*corrupted*) yang dilewati sistem.
- **Pembagian Data:** Terbagi menjadi 16.283 sampel *training* (70%), 3.490 sampel *validation* (15%), dan 3.489 sampel *testing* (15%).

III. PREPROCESSING DATA

Langkah *preprocessing* disesuaikan dengan arsitektur target masing-masing eksperimen:

- **Eksperimen 1 (CIFAR-10):** Citra digital diubah tipe datanya menjadi `float32`, lalu nilainya dinormalisasi dari rentang $[0, 255]$ ke skala $[0.0, 1.0]$ melalui pembagian `255.0`. Data ditata menggunakan skema *mini-batch* sebesar 64 dan diacak (*shuffle*) setiap *epoch*.
- **Eksperimen 2 (Cats vs Dogs):** Citra di-*resize* secara spasial menjadi 160×160 piksel. Normalisasi piksel dilakukan menggunakan fungsi khusus `tf.keras.applications.mobilenet_v2.preprocess_i` yang menyeimbangkan nilai piksel ke rentang $[-1.0, 1.0]$ sesuai spesifikasi standar input bobot ImageNet. Untuk

meningkatkan fleksibilitas *data pipeline*, diterapkan teknik *prefetching* (`tf.data.AUTOTUNE`).

IV. IMPLEMENTASI CNN FROM SCRATCH

Arsitektur CNN kustom dirancang secara berhierarki menggunakan blok konvolusi dan regularisasi sebagai berikut:

- 1) **Input Layer:** `layers.Input(shape=(32, 32, 3))`
- 2) **Blok Konvolusi 1:**
 - `Conv2D(32, (3,3), activation='relu', padding='same')` (896 param)
 - `BatchNormalization()` (128 param)
 - `Conv2D(32, (3,3), activation='relu')` (9.248 param)
 - `MaxPooling2D((2,2))` untuk reduksi dimensi spasial.
 - `Dropout(0.25)` untuk mencegah ketergantungan antar-neuron.
- 3) **Blok Konvolusi 2:**
 - `Conv2D(64, (3,3), activation='relu', padding='same')` (18.496 param)
 - `BatchNormalization()` (256 param)
 - `Conv2D(64, (3,3), activation='relu')` (36.928 param)
 - `MaxPooling2D((2,2))`
 - `Dropout(0.25)`
- 4) **Classification Head:**
 - `Flatten()`
 - `Dense(128, activation='relu')` (295.040 param)
 - `Dropout(0.5)`
 - `Dense(10, activation='softmax')` (1.290 param)
- 5) **Total Parameter:** 362.282 parameter (362.090 *trainable*, 192 *non-trainable*).
- 6) **Optimizer & Loss:** Optimizer Adam (`learning_rate = 0.001`) dengan *loss function* `sparse_categorical_crossentropy`.

V. IMPLEMENTASI TRANSFER LEARNING

Implementasi *Transfer Learning* memanfaatkan arsitektur MobileNetV2 dengan pendekatan *Feature Extraction*:

- 1) **Base Model:** MobileNetV2 tanpa *top classification layer* (`include_top=False`) yang dimuat dengan bobot *pretrained* 'imagenet'.
- 2) **Freezing Layer:** Seluruh lapisan dasar dibekukan (`base_model.trainable = False`) agar bobot ekstraksi fitur dasar dari ImageNet tidak terdistorsi selama proses pelatihan.
- 3) **Classification Head Baru:**
 - `layers.Input(shape=(160, 160, 3))`
 - `base_model`
 - `GlobalAveragePooling2D()`

- `Dropout(0.2)`
- `Dense(1, activation='sigmoid')` untuk estimasi probabilitas biner.

- 4) **Optimizer & Loss:** Optimizer Adam (`learning_rate = 0.001`) dengan *loss function* `binary_crossentropy`.

VI. HASIL EKSPERIMEN

Eksperimen dijalankan pada lingkungan cloud Kaggle berbasis GPU Tesla P100 (15,1 GB VRAM).

A. Eksperimen 1: CNN from Scratch

- **Proses Latih (15 Epoch):** Berjalan rata-rata 3 detik/epoch. Pada epoch ke-15, didapatkan *accuracy training* sebesar 0.7570, *loss training* 0.7047, *validation accuracy* 0.7769, dan *validation loss* 0.6790.
- **Hasil Testing Akhir:** Akurasi data testing menyentuh angka **77.09%** dengan *loss testing* **0.6913**.

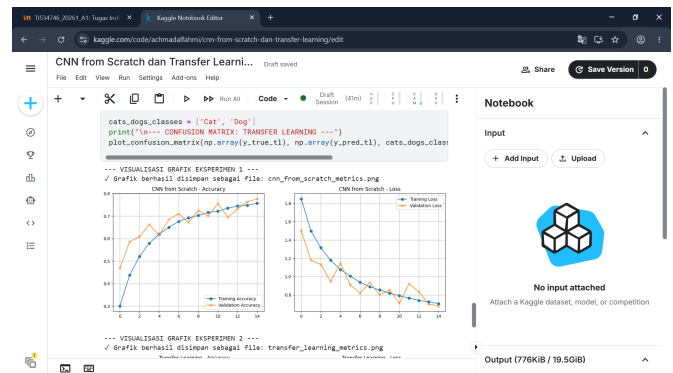


Fig. 1. Grafik Akurasi dan Loss Training vs Validation CNN from Scratch.




Fig. 2. Confusion Matrix CNN from Scratch pada Dataset CIFAR-10.

B. Eksperimen 2: Transfer Learning (MobileNetV2)

- **Proses Latih (10 Epoch):** Berjalan rata-rata 17 detik/epoch (1.018 batch). Pada epoch ke-10, didapatkan *accuracy training* sebesar 0.9881, *loss training* 0.0322, *validation accuracy* 0.9840, dan *validation loss* 0.0513.
- **Hasil Testing Akhir:** Evaluasi pada 219 batch testing menghasilkan akurasi data testing **98.11%** dengan *loss testing* **0.0591**.




Fig. 3. Contoh Hasil Prediksi Benar dan Salah pada Model CNN from Scratch.




Fig. 4. Grafik Akurasi dan Loss Training vs Validation Transfer Learning.

C. Eksperimen 2: Transfer Learning (MobileNetV2)

- **Proses Latih (10 Epoch):** Berjalan rata-rata 17 detik/epoch (1.018 batch). Pada epoch ke-10, didapatkan *accuracy training* sebesar 0.9881, *loss training* 0.0322, *validation accuracy* 0.9840, dan *validation loss* 0.0513.
- **Hasil Testing Akhir:** Evaluasi pada 219 batch testing menghasilkan akurasi data testing **98.11%** dengan *loss testing* **0.0591**.




Fig. 5. Confusion Matrix Transfer Learning pada Dataset Cats vs Dogs.

Fig. 6. Grafik Akurasi dan Loss Training vs Validation Transfer Learning.

VII. PERBANDINGAN MODEL

Tabel I merangkum perbandingan komparatif hasil eksperimen dari kedua model berbasis riwayat eksekusi nyata.

TABLE I
TABEL PERBANDINGAN CNN FROM SCRATCH DAN TRANSFER LEARNING

Aspek	CNN from Scratch	Transfer Learning
Akurasi Training	75.70% (0.7570)	98.81% (0.9881)
Akurasi Validation	77.69% (0.7769)	98.40% (0.9840)
Akurasi Testing	77.09% (0.7709)	98.11% (0.9811)
Loss Training	0.7047	0.0322
Loss Validation	0.6790	0.0513
Waktu Training	~45 detik	~170 detik
Jumlah Parameter	362.282 (1.38 MB)	~2.25 Juta
Risiko Overfitting	Sedang	Sangat Rendah
Kemudahan Implementasi	Perlu rancang manual	Praktis (Pretrained)
Kesesuaian Dataset	Citra kecil (32×32)	Citra kompleks (160×160)

VIII. ANALISIS KAPAN MEMILIH CNN DAN TRANSFER LEARNING

A. Analisis Dataset

- 1) **Kecukupan Dataset:** Dataset CIFAR-10 (60.000 gambar) dan Cats vs Dogs (23.262 gambar) sangat cukup untuk pelatihan. Namun, untuk CNN *from scratch*, sampel yang lebih sedikit akan memicu *overfitting* fatal.
- 2) **Variasi Gambar:** Variasi sudut pandang, skala, dan pencahayaan pada kedua dataset sudah sangat baik.
- 3) **Keseimbangan Data:** Kedua dataset memiliki distribusi kelas yang seimbang.
- 4) **Noise & Background:** Cats vs Dogs memiliki *background* yang sangat kompleks dan variasi pose yang tinggi.
- 5) **Pengaruh Kualitas Dataset:** *Background* kompleks berhasil diatasi secara unggul oleh *Transfer Learning* karena MobileNetV2 sudah dilatih memisahkan objek utama pada ImageNet.

B. Analisis Performa Model

- 1) **Performa Terbaik:** *Transfer Learning* menghasilkan akurasi *testing* jauh lebih tinggi (98.11% vs 77.09%).
- 2) **Akurasi vs Kualitas Model:** Akurasi *training* yang sangat tinggi tanpa diimbangi akurasi *validation* menandakan *overfitting*.
- 3) **Tanda Overfitting:** CNN *from scratch* menunjukkan fluktuasi *val_loss* pada pertengahan epoch, sedangkan *Transfer Learning* sangat stabil.
- 4) **Stabilitas Latihan:** *Transfer Learning* jauh lebih stabil karena bobot awal tidak bernilai acak.

C. Analisis Pemilihan Pendekatan Utama

- **Gunakan CNN from Scratch jika:** Dataset berukuran masif (> 100.000 gambar), domain data sangat khusus/spesifik (seperti citra medis X-Ray atau radar), ukuran citra sangat kecil ($< 32 \times 32$), serta terdapat kebutuhan *deployment* pada perangkat *embedded* ultra-ringan.
- **Gunakan Transfer Learning jika:** Dataset berukuran terbatas (< 10.000 gambar), objek citra bersifat umum

(dunia nyata), ketersediaan waktu dan komputasi terbatas, serta membutuhkan akurasi tinggi secara instan.

IX. JAWABAN STUDI KASUS PENGAMBILAN KEPUTUSAN

- **Skenario 1 (Klinik Citra Medis, 300 Gambar):** *Transfer Learning dengan Fine-Tuning*. Jumlah 300 gambar terlalu sedikit untuk CNN *from scratch*. Menggunakan *pretrained model* (seperti ResNet/DenseNet) yang di-*fine-tune* pada *top layers* adalah solusi paling rasional.
- **Skenario 2 (1 Juta Gambar Produk Internal Spesifik Non-ImageNet):** *CNN from Scratch*. Dengan 1 juta gambar dan GPU memadai, model memiliki data yang cukup untuk mempelajari fitur unik produk dari nol tanpa terdistorsi oleh *bias* bobot ImageNet.
- **Skenario 3 (Prototipe 2 Hari, 500 Gambar):** *Transfer Learning (Feature Extraction)*. Pelatihan *feature extraction* hanya membutuhkan waktu beberapa menit pada classifier head, sangat pas untuk *deadline* singkat.
- **Skenario 4 (Dataset Besar + GPU Memadai untuk Domain Spesifik):** *Transfer Learning Tetap Digunakan (Inisialisasi Bobot)*. Menggunakan bobot *pretrained* sebagai titik awal sebelum *full fine-tuning* akan mempercepat konvergensi dibanding inisialisasi acak.

X. KESIMPULAN DAN REFLEKSI PRIBADI

A. Kesimpulan

Praktikum ini berhasil membuktikan bahwa *Transfer Learning* berbasis MobileNetV2 mengungguli CNN *from scratch* secara signifikan (98.11% vs 77.09%) dari segi akurasi dan stabilitas konvergensi. Meski demikian, CNN *from scratch* tetap relevan untuk dipelajari guna memahami fondasi kerja lapisan konvolusi dan regularisasi jaringan saraf tiruan.

B. Refleksi Pribadi

- 1) **Tantangan Terbesar:** Mengatasi masalah jaringan/link dataset saat pengunduhan serta menyesuaikan fungsi normalisasi piksel spesifik (*preprocess_input*) pada MobileNetV2 agar tidak terjadi *mismatch* distribusi data.
- 2) **Bagian Paling Sulit:** CNN *from scratch*, karena harus merancang kombinasi layer konvolusi, pooling, dan regularisasi secara manual agar model tidak mudah *overfitting*.
- 3) **Perbedaan Paling Terasa:** Kecepatan konvergensi dan stabilitas. *Pretrained model* langsung mencapai akurasi tinggi pada *epoch* pertama, sedangkan CNN *from scratch* membutuhkan waktu lama untuk menemukan pola dasar.
- 4) **Pendekatan Kasus Nyata:** *Transfer Learning*, karena efisien dari segi waktu pelatihan, penggunaan memori komputasi, dan minim risiko *overfitting*.
- 5) **Pelajaran Pengambilan Keputusan:** Keputusan *Deep Learning* bersifat *data-centric*. Ukuran dataset, kemiripan domain, dan batas komputasi menentukan pendekatan terbaik.

REFERENCES

- [1] A. Krizhevsky, "Learning Multiple Layers of Features from Tiny Images," Master's thesis, University of Toronto, 2009.
- [2] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," in *Proc. IEEE Conf. Comput. Vis. Pattern Recog. (CVPR)*, 2018, pp. 4510–4520.
- [3] F. Chollet, "Xception: Deep Learning with Depthwise Separable Convolutions," in *Proc. IEEE Conf. Comput. Vis. Pattern Recog. (CVPR)*, 2017, pp. 1251–1258.
- [4] TensorFlow Datasets, "Cats vs Dogs Dataset," Google Developers, 2023. [Online]. Available: https://www.tensorflow.org/datasets/catalog/cats_vs_dogs.